

Implementación del método de la máxima verosimilitud para la regresión logística.

Definir la función de entorno L(b)

$$L(\beta) = \sum_i^n y_i \ln P_i + (1 - y_i) \ln (1 - P_i)$$

```
In [1]: def likelihood(y, pi):
import numpy as np
total_sum = 1
sum_in = list(range(1, len(y)+1))
for i in range(len(y)):
    sum_in[i] = np.where(y[i]==1, pi[i], 1-pi[i])
    total_sum = total_sum * sum_in[i]
return total_sum
```

Calcular las probabilidades para cada observación

$$L(\beta) = P_i = P(x_i) = \frac{1}{1 + e^{-\sum_{j=0}^k (\beta_j \cdot X_{ij})}}$$

```
In [2]: def logitprobs(X, beta):
import numpy as np
n_rows = np.shape(X)[0]
n_cols = np.shape(X)[1]
pi = list(range(1, n_rows+1))
expon = list(range(1, n_rows+1))
for i in range(n_rows): # Este for es para las i, o sea para las probabilidades
    expon[i] = 0
    for j in range(n_cols): # Calculo el sumatorio de las k columnas, y saco el exponente
        ex = X[i][j] * beta[j] # Producto de los exponentes Beta_j y X_ij
        expon[i] = ex + expon[i] # Suma total de los exponentes
    with np.errstate(divide="ignore", invalid="ignore"):
        pi[i] = 1 / (1 + np.exp(-expon[i]))
return pi
```

Calcular la matriz diagonal W

$$\omega(\beta) = \text{diag}(P_i \cdot (1 - P_i))_{i=1}^n$$

```
In [3]: def findW(pi):
import numpy as np
n = len(pi)
W = np.zeros(n*n).reshape(n,n) # Creo un vector de 0s y luego una matriz de n x n de ceros con reshape
for i in range(n):
    print(i)
    W[i, i] = pi[i] * (1 - pi[i])
    W[i, i].astype(float)
return W
```

Definir la función logística

$$\Delta\beta = \frac{f(\beta)}{f'(\beta)}$$

$$f(\beta) = \frac{\partial l}{\partial \beta} = X \cdot (y - P(\beta))$$

$$f'(\beta) = \frac{\partial^2 l}{\partial \beta^2} = X \cdot \omega(\beta) \cdot X^t$$

```
In [34]: def logistics(X, Y, limit): # El límite del cambio de un paso al siguiente hasta que converja
from numpy import linalg
nrow = np.shape(X)[0]
bias = np.ones(nrow).reshape(nrow, 1)
X_new = np.append(X, bias, axis = 1) # Agrego una columna de unos a la derecha de los datos, aux.
```

```

ncol = np.shape(X_new)[1] #Número de columnas en la posición 1 porque tendrá una más que antes.
beta = np.zeros(ncol).reshape(ncol, 1) #Toda una col de 0 de la misma lon que e ncol, apiladas
root_dif = np.array(range(1,ncol+1)).reshape(ncol,1) #Diferencias entre las raíces / los betas.
iter_i = 10000
counter = 0
while (iter_i>limit):
    print("El producto de iteraciones es iter_i: " + str(iter_i) + ", El límite es: " + str(limit))
    pi = logitprobs(X_new, beta)
    print ("El valor de las probabilidades parciales Pi es: " + str(pi))
    W = findW(pi)
    print("La matriz es W: " + str(W))
    #num y den, que son numerador y denominador se transponen para poder ser multiplicadas.
    num = (np.transpose(np.matrix(X_new))*np.matrix(Y-np.transpose(pi)).transpose())
    den = (np.matrix(np.transpose(X_new))*np.matrix(W)*np.matrix(X_new))
    root_dif = np.array(linalg.inv(den)*num) #Acá está el delta beta calculado
    beta = beta + root_dif
    print("El valor de beta es: " + str(beta))
    iter_i = np.sum(root_dif*root_dif)
    ll = likelihood(Y, pi) #Factor de verosimilitud
    counter += 1
    print("El n° iteraciones a la que converge es : " + str(counter))
return beta

```

Comprobación experimental

```
In [35]: import numpy as np
```

```
In [36]: X = np.array(range(10)).reshape(10,1)
X
```

```
Out[36]: array([[0],
 [1],
 [2],
 [3],
 [4],
 [5],
 [6],
 [7],
 [8],
 [9]])
```

```
In [37]: Y = [0,0,0,0,1,0,1,0,1,1]
```

```
In [38]: bias = np.ones(10).reshape(10,1)
X_new = np.append(X, bias, axis = 1)
```

```
In [39]: X_new
```

```
Out[39]: array([[0., 1.],
 [1., 1.],
 [2., 1.],
 [3., 1.],
 [4., 1.],
 [5., 1.],
 [6., 1.],
 [7., 1.],
 [8., 1.],
 [9., 1.]])
```

```
In [41]: a = logistics(X, Y, 0.00001)
```

```

El producto de iteraciones es iter_i: 10000, El límite es: 1e-05
El valor de las probabilidades parciales Pi es: [array([0.5]), array([0.5]), array([0.5]), array([0.5]),
array([0.5]), array([0.5]), array([0.5]), array([0.5]), array([0.5]), array([0.5])]
0
1
2
3

```

4
5
6
7
8
9

La matriz es W: [[0.25 0. 0. 0. 0. 0. 0. 0. 0. 0.]

```
[0. 0.25 0. 0. 0. 0. 0. 0. 0. 0. ]
[0. 0. 0.25 0. 0. 0. 0. 0. 0. 0. ]
[0. 0. 0. 0.25 0. 0. 0. 0. 0. 0. ]
[0. 0. 0. 0. 0.25 0. 0. 0. 0. 0. ]
[0. 0. 0. 0. 0. 0.25 0. 0. 0. 0. ]
[0. 0. 0. 0. 0. 0. 0.25 0. 0. 0. ]
[0. 0. 0. 0. 0. 0. 0. 0.25 0. 0. ]
[0. 0. 0. 0. 0. 0. 0. 0. 0.25 0. ]
[0. 0. 0. 0. 0. 0. 0. 0. 0. 0.25]]
```

El valor de beta es: [[0.43636364]
[-2.36363636]]

El nº iteraciones a la que converge es :1

El producto de iteraciones es iter_i: 5.777190082644626, El límite es: 1e-05

El valor de las probabilidades parciales Pi es: [array([0.08598797]), array([0.12705276]), array([0.18378532]), array([0.2583532]), array([0.35019508]), array([0.45467026]), array([0.56329497]), array([0.66616913]), array([0.75533524]), array([0.82687453])]

0
1
2
3
4
5
6
7
8
9

La matriz es W: [[0.07859404 0. 0. 0. 0.

```
0. 0. 0. 0. ]
[0. 0.11091035 0. 0. 0. 0.
0. 0. 0. 0. ]
[0. 0. 0.15000827 0. 0. 0.
0. 0. 0. 0. ]
[0. 0. 0. 0.19160683 0. 0.
0. 0. 0. 0. ]
[0. 0. 0. 0. 0.22755849 0.
0. 0. 0. 0. ]
[0. 0. 0. 0. 0. 0.24794521
0. 0. 0. 0. ]
[0. 0. 0. 0. 0. 0.
0.24599375 0. 0. 0. ]
[0. 0. 0. 0. 0. 0.
0. 0.22238782 0. 0. ]
[0. 0. 0. 0. 0. 0.
0. 0. 0.18480392 0. ]
[0. 0. 0. 0. 0. 0.
0. 0. 0. 0.14315304]]
```

El valor de beta es: [[0.60426056]
[-3.34641372]]

El nº iteraciones a la que converge es :2

El producto de iteraciones es iter_i: 0.9940407075349111, El límite es: 1e-05

El valor de las probabilidades parciales Pi es: [array([0.0340128]), array([0.06053134]), array([0.10546805]), array([0.1774629]), array([0.28305225]), array([0.41943069]), array([0.56933774]), array([0.7075284]), array([0.81572841]), array([0.89011647])]

0
1
2
3
4
5
6
7
8
9

La matriz es W: [[0.03285593 0. 0. 0. 0.

```
0. 0. 0. 0. ]
[0. 0.0568673 0. 0. 0. 0.
0. 0. 0. 0. ]
[0. 0. 0.09434454 0. 0. 0.]
```

0.	0.	0.	0.]	
[0.	0.	0.	0.14596982	0.	0.
0.	0.	0.	0.]	
[0.	0.	0.	0.	0.20293367	0.
0.	0.	0.	0.]	
[0.	0.	0.	0.	0.	0.24350859
0.	0.	0.	0.]	
[0.	0.	0.	0.	0.	0.
0.24519228	0.	0.	0.]	
[0.	0.	0.	0.	0.	0.
0.	0.20693196	0.	0.]	
[0.	0.	0.	0.	0.	0.
0.	0.	0.15031557	0.]	
[0.	0.	0.	0.	0.	0.
0.	0.	0.	0.09780914]	

El valor de beta es: [[0.65761412]
[-3.66759924]]

El nº iteraciones a la que converge es :3

El producto de iteraciones es iter_i: 0.10600674406801981, El límite es: 1e-05

El valor de las probabilidades parciales Pi es: [array([0.02490177]), array([0.04697681]), array([0.0868775]), array([0.15515129]), array([0.26170168]), array([0.40624059]), array([0.56907679]), array([0.71823018]), array([0.83108181]), array([0.90473054])]

0
1
2
3
4
5
6
7
8
9

La matriz es W: [[0.02428167 0. 0. 0. 0.]

0.	0.	0.	0.]	
[0.	0.04476999	0.	0.	0.	0.
0.	0.	0.	0.]	
[0.	0.	0.0793298	0.	0.	0.
0.	0.	0.	0.]	
[0.	0.	0.	0.13107937	0.	0.
0.	0.	0.	0.]	
[0.	0.	0.	0.	0.19321391	0.
0.	0.	0.	0.]	
[0.	0.	0.	0.	0.	0.24120917
0.	0.	0.	0.]	
[0.	0.	0.	0.	0.	0.
0.2452284	0.	0.	0.]	
[0.	0.	0.	0.	0.	0.
0.	0.20237559	0.	0.]	
[0.	0.	0.	0.	0.	0.
0.	0.	0.14038483	0.]	
[0.	0.	0.	0.	0.	0.
0.	0.	0.	0.08619319]	

El valor de beta es: [[0.66217766]
[-3.6953843]]

El nº iteraciones a la que converge es :4

El producto de iteraciones es iter_i: 0.0007928351246008185, El límite es: 1e-05

El valor de las probabilidades parciales Pi es: [array([0.02423594]), array([0.04594805]), array([0.08540873]), array([0.15331276]), array([0.25986436]), array([0.40504298]), array([0.56897776]), array([0.71907124]), array([0.83230289]), array([0.90586963])]

0
1
2
3
4
5
6
7
8
9

La matriz es W: [[0.02364856 0. 0. 0. 0.]

0.	0.	0.	0.]	
[0.	0.04383683	0.	0.	0.	0.
0.	0.	0.	0.]	
[0.	0.	0.07811408	0.	0.	0.
0.	0.	0.	0.]	

```

[0.      0.      0.      0.12980796 0.      0.
 0.      0.      0.      0.      ]
[0.      0.      0.      0.      0.19233487 0.
 0.      0.      0.      0.      ]
[0.      0.      0.      0.      0.      0.24098316
 0.      0.      0.      0.      ]
[0.      0.      0.      0.      0.      0.
 0.24524207 0.      0.      0.      ]
[0.      0.      0.      0.      0.      0.
 0.      0.20200779 0.      0.      ]
[0.      0.      0.      0.      0.      0.
 0.      0.      0.13957479 0.      ]
[0.      0.      0.      0.      0.      0.
 0.      0.      0.      0.08526985]]

```

El valor de beta es: [[0.66220827]

[-3.69557172]]

El n° iteraciones a la que converge es :5

La ecuación conchasumadre es: $Y = 0.66220827 - 3.69557172X$ esto es lo que vendría siendo el exponente de la función logística:

$$P = \frac{1}{1 + e^{-(0.66220827 - 3.69557172X)}}$$

```
In [11]: ll = likelihood (Y, logitprobs(X,a))
```

```
In [12]: ll #La suma total
```

```
Out[12]: array([1.32622426e-06])
```

Con el paquete statsmodel de python

```
In [13]: import statsmodels.api as sm
```

```
In [14]: logit_model = sm.Logit(Y, X_new)
```

```
In [15]: result = logit_model.fit()
```

Optimization terminated successfully.

Current function value: 0.431012

Iterations 6

```
In [43]: print(result.summary2())
```

```

Results: Logit
=====
Model:                Logit                Pseudo R-squared: 0.360
Dependent Variable:    y                    AIC:                12.6202
Date:                 2022-03-24 15:30       BIC:                13.2254
No. Observations:     10                    Log-Likelihood:     -4.3101
Df Model:              1                    LL-Null:            -6.7301
Df Residuals:          8                    LLR p-value:        0.027807
Converged:             1.0000                Scale:             1.0000
No. Iterations:        6.0000

-----
              Coef.    Std.Err.      z      P>|z|      [0.025    0.975]
-----
x1           0.6622     0.4001     1.6551   0.0979   -0.1220    1.4464
const       -3.6956     2.2889   -1.6145   0.1064   -8.1818    0.7906
=====

```

Como podemos ver en el summary x1 es el eje de coordenadas y const el factor de multiplicación y

estos coinciden exactamente con nuestro modelo, por lo que podemos decir es que nuestro programa

está bien hecho y la aproximación de Newton - Rapson están bien calculados.

