## SVM para Regresión

```
In [1]:
           import numpy as np
           import matplotlib.pyplot as plt
In [11]:
          X = np.sort(5*np.random.rand(200,1), axis=0)
          Y = np.sin(X).ravel()
          Y[::5] += 3*(0.5-np.random.rand(40)) # ::5 sginifica que de 5 en 5 va a crear un número alea
In [12]:
           plt.scatter(X,Y, color = "darkorange", label = "data")
          <matplotlib.collections.PathCollection at 0x278fa573ac0>
Out[12]:
           2
           1
           0
          -1
          -2
In [15]:
          from sklearn.svm import SVR
In [16]:
           C=1e3
          svr_lin = SVR(kernel="linear", C=C)
          svr_rbf = SVR(kernel="rbf", C=C, gamma = 0.1)
          svr_pol = SVR(kernel="poly", C=C, degree=3)
         Lo ideal sería hacer validación cruzada, obtener óptimamente los valores, etc. Pero simplemente vamos a
         ver cómo se emplean los SVR para cada tipo de kernel.
In [17]:
          y lin = svr lin.fit(X,Y).predict(X)
          y rbf = svr rbf.fit(X,Y).predict(X)
          y_pol = svr_pol.fit(X,Y).predict(X)
In [18]:
          lw = 2
          plt.figure(figsize=(16,9))
          plt.scatter(X,Y, color="darkorange", label = "data")
          plt.plot(X, y_lin, color="navy", lw=lw, label="SVM Lineal")
          plt.plot(X, y_rbf, color="c", lw=lw, label = "SVM Radial")
          plt.plot(X, y_pol, color="cornflowerblue", label="SVM Polinómico")
          plt.xlabel("x")
          plt.ylabel("y")
          plt.title("Support Vector Regression")
          plt.legend()
          plt.show()
```

